AdaptCLIP：面向通用视觉异常检测的 CLIP 适配方法

Bin-Bin Gao[1] Yue Zhou [2,3] Jiangtao Yan [1] Yuezhi Cai [2]
Weixi Zhang [2] Meng Wang [2] Jun Liu [1] Yong Liu [1] Lei Wang [2] Chengjie Wang[1,4]
[1]Tencent YouTu Lab [2]Siemens AG [3]Technical University of Munich [4]Shanghai Jiao Tong University

Abstract

通用视觉异常检测旨在无需额外微调的情况下，从新的或未见过的视觉域中识别异常，这对于开放场景至关重要。近期研究表明，像 *CLIP* 这样的预训练视觉语言模型仅凭零样本或少量正常图像就表现出很强的泛化能力。然而，现有方法在提示模板设计、复杂 *token* 交互，或额外微调需求方面仍存在困难，因此灵活性有限。本文基于两个关键观察，提出一种简单而有效的方法 *AdaptCLIP*。第一，自适应视觉表示与文本表示应当交替学习，而不是联合学习。第二，查询图像与正常图像提示之间的比较学习，不应仅依赖残差特征，而应同时结合上下文特征与对齐后的残差特征。*AdaptCLIP* 将 *CLIP* 视为基础服务，只在输入端或输出端增加三个简单适配器：视觉适配器、文本适配器和提示-查询适配器。*AdaptCLIP* 支持跨域的零样本与少样本泛化，并且在基准数据集上训练完成后，在目标域上无需训练。*AdaptCLIP* 在来自工业和医疗领域的 *12* 个异常检测基准上取得了最先进的性能，显著优于现有有竞争力的方法。我们将公开 *AdaptCLIP* 的代码和模型：https://github.com/gaobb/AdaptCLIP。

1. 引言

通用视觉异常检测（Anomaly Detection, AD）旨在：在一个基础数据集或已见数据集上学习出单一模型后，能够在新的或未见过的视觉对象上识别异常图像并分割异常像素。这一任务更具挑战性，因为它要求模型在跨域数据集上具备较强的泛化能力。同时，它也更具现实意义，因为在真实场景中，人们更关注模型的快速适应能力，尤其是在低数据场景下（即少样本，甚至零样本）。例如，在医学影像诊断和工业视觉质检中，由于天然稀缺性和隐私保护的限制，很难收集大规模数据集。近年来，通用视觉异常检测受到越来越多关注，因为现有无监督异常检测方法无论是采用分离式模型 [8, 25, 34] 还是统一式模型 [11, 48]，虽然在已见对象上效果不错，但在未见对象上的性能较差。

方法	ZS	FS	OA	无 FT
WinCLIP [16]	✓	✓	✓	✓
AdaCLIP [6]	✓	✗	✗	✓
InCtrl [54]	✗	✓	✓	✓
AnomalyCLIP [53]	✓	✗	✗	✓
PromptAD [23]	✗	✓	✓	✗
AdaptCLIP	✓	✓	✓	✓

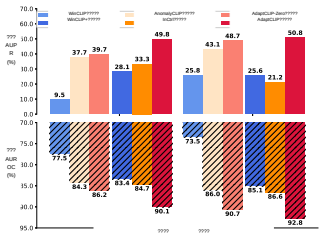

图 1. 现有最先进方法与我们的 **AdaptCLIP** 对比。✓ 表示满足，✗ 表示不满足。我们的方法支持在不同领域上进行零样本/少样本（ZS 和 FS）视觉异常检测，并且无需在目标数据集上微调（FT）。它只在 CLIP 的输入端或输出端增加简单适配器，而不引入复杂的 token 交互，因此能够保留 CLIP 的原始能力（OA）。仅使用一张正常图像提示的 AdaptCLIP，在工业和医疗领域的 12 个异常检测基准上，在图像级异常分类（I-AUROC）和像素级异常分割（P-AUPR）中都取得了最佳性能。此外，零样本 AdaptCLIP 也显著优于现有零样本方法，甚至优于部分单样本方法。图中给出了主结果摘要。建议放大查看。

为了解决这一割裂问题，近期工作开始尝试设计能够识别未见对象异常的通用模型。它们通常构建在视觉语言模型（如 CLIP [29]）之上，以利用其强泛化能力。WinCLIP [16] 在稠密 patch 窗口上计算异常分数，但这带来了较大的计算开销和内存负担，限制了高分辨率输入或大规模预训练模型的使用。AnomalyCLIP [53] 通过学习与类别无关的提示嵌入来对齐 patch 级 token，从而避免稠密窗口操作；它还通过向 CLIP 中间层拼接

可学习 token 来进一步改造原始 CLIP。AdaCLIP [6] 则进一步将视觉知识融入文本提示嵌入中。然而，这些方法可能会破坏 CLIP 的内在表征。因此，*我们希望探索：是否能够在保持原始能力的同时，达到相同甚至更好的异常检测性能。*

与此相对，人类通常在输入明显偏离大脑中所存储的正常模式时感知异常。神经科学中已有证据支持这一观点 [31]。PatchCore [34] 构建了一个存储正常特征的记忆库，PaDiM [7] 则学习正常特征的多元高斯分布。在推理时，异常通过将输入特征与记忆库或已学习分布进行比较而被识别。然而，这类方法通常需要一定数量的正常图像，因此在通用（即开放世界）场景中受限。近期两项工作 InCtrl [54] 和 PromptAD [23] 研究了如何利用少量正常图像进一步提升性能。但 InCtrl 仅考虑异常分类，而 PromptAD 需要为每个类别重新训练新模型。不同于它们，*我们希望全面探索一个通用异常检测模型，目标是在目标域完全不训练的前提下，实现跨域的图像级和像素级异常检测。*

基于这一目标，我们提出了一个简单而有效的通用视觉异常检测框架，称为 AdaptCLIP。*AdaptCLIP 的核心理念是“更少且更简单，反而可能更好”，它包含由两个关键洞察驱动设计的三个适配器：*第一，自适应视觉表示与文本表示应交替学习，而不是联合学习。第二，查询图像与对应正常图像提示之间的比较学习，不应只依赖残差特征，而应同时融合上下文特征与对齐后的残差特征。我们的贡献概括如下。

- 我们提出了一个基于视觉语言 CLIP 模型的简单而有效的通用视觉异常检测框架，能够在不对目标域进行任何训练的前提下，对跨域数据集中的任意视觉异常进行图像级和像素级检测。
- 我们提出了视觉适配器和文本适配器，并发现它们应在 CLIP 强大的视觉语言表征引导下交替学习自适应视觉表示和文本表示。
- 我们提出了提示-查询适配器，旨在基于查询图像上下文特征与提示图像和查询图像之间对齐残差特征的联合分布，捕获查询图像与对应正常图像提示之间的元感知能力。
- 如图 1 所示，AdaptCLIP 在 8 个工业基准和 4 个医疗基准上优于零样本与少样本异常检测方法。同时，AdaptCLIP 具有更简单的适配器、更少的参数量以及有竞争力的效率。

2. 相关工作

无监督异常检测。无监督异常检测旨在在给定充足正常训练图像的情况下识别异常。大多数无监督异常检测方法大致可分为三类：基于嵌入的方法、基于判别的方法以及基于重建的方法。基于嵌入的方法，如 PaDiM [7]、MDND [32]、PatchCore [34]、CS-Flow [35] 和 PyramidFlow [19]，假设从预训练模型中离线提取的特征保留了判别信息，因此有助于将异常样本与正常样本分开。基于判别的方法，如 CutPaste [21]、DRAEM [50] 和 SimpleNet [25]，通常通过引入伪造的（合成的）异常样本，将无监督异常检测转化为有监督任务。基于重建的方法，如自编码器 [2, 12, 14, 40]、生成对抗网络 [27, 45, 49] 以及重建网络 [24, 33, 51]，则假设异常区域无法被正确重建，因此会产生较大的重建误差，因为它们在正常训练样本中并不存在。近期的知识蒸馏 [4, 8, 36, 42, 43] 或特征重建方法 [11, 46, 48, 52]，通过训练学生网络或重建网络去匹配固定的预训练教师网络，在效果与效率之间取得了较好平衡。然而，这些方法都局限于识别已见类别的异常，在未见类别上通常表现较差。面对新场景时，人们必须先收集充足的正常图像，再重新训练模型。这种方式效率低下，也无法满足实际应用对快速适应性的需求。

零样本异常检测。零样本异常检测借助大规模视觉语言模型（如 CLIP [29]）已经取得了令人印象深刻的性能。WinCLIP [16] 设计了二分类文本提示，并引入多尺度 patch 窗口以实现精确的异常分割，但这也带来了较大的计算开销和内存负担，限制了高分辨率输入和大模型的使用。AnomalyCLIP [53] 学习与类别无关的提示嵌入来对齐 patch 级 token，从而避免了稠密窗口操作；此外，它还通过在 CLIP 中间层附加一些可学习 token 来改进原始 CLIP 表征。近期的 AdaCLIP [6] 和 VCP-CLIP [28] 延续了类似思路，并进一步将视觉知识融入文本提示嵌入。我们认为，这些额外操作会使模型更加复杂，并可能削弱 CLIP 的原始能力。与视觉语言模型路线不同，ACR [20] 和 MuSc [22] 仅依赖批级或全样本测试图像来完成零样本异常检测，但在隐私保护场景中可能受到限制。不同于这些方法，我们关注的是：在不使用任何测试数据分布信息的前提下，是否能够在保留 CLIP 原始能力的同时获得相同甚至更好的异常检测性能。

少样本异常检测。少样本异常检测主要关注只利用有

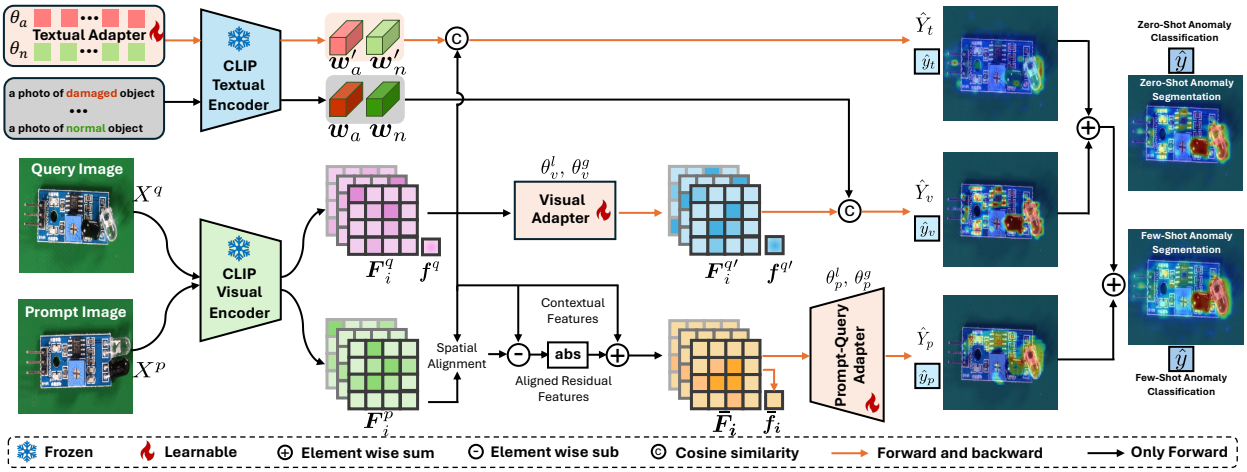

图 2. **AdaptCLIP** 的整体框架，由三个可插拔适配器组成：视觉适配器、文本适配器和提示-查询适配器。首先，前两个适配器交替学习视觉表示和文本表示，用于零样本异常检测（第 3.2 节）。随后，提示-查询适配器进一步学习查询图像与对应正常图像提示之间的比较能力，用于少样本异常检测（第 3.3 节）。模型一旦训练完成，只需提供少量甚至零张正常图像提示，就能分割任意异常。

限数量正常图像进行学习或推理，例如 TDG [37]、RegAD [15]、GraphCore [44] 和 FastRecon [10]。还有一些工作 [9, 47] 研究了另一种少样本设定，即给定少量异常图像样本，但这些方法的性能仍落后于无监督异常检测。近期，视觉语言模型显著提升了少样本异常检测性能。WinCLIP+ [16] 是首个将 CLIP 用于少样本异常检测的方法，它将正常 token 存入记忆库，再通过余弦相似度为每个查询 token 检索最近邻 token，最后利用最近距离计算异常图。InCtrl [54] 进一步融合了多层次信息，包括 patch 级残差图、图像级残差特征，以及基于二分类文本提示得到的先验知识分数，以学习整体异常评分函数，用于异常分类，但它没有考虑像素级异常分割。PromptAD [23] 引入了显式异常间隔，以缓解缺乏异常训练图像所带来的训练困难，但它在应用到目标数据集时需要重新训练模型。相比之下，我们探索的是在统一模型中联合优化异常分类与异常分割，使模型在仅给定少量正常图像提示的情况下就能快速适应新场景，而无需额外重训练。

3. 方法

问题定义：我们的目标是学习一个通用异常检测模型，使其在目标数据集上完全不训练的前提下，能够检测来自多样领域的任意异常。因此，一个合理假设是训练集与测试集之间存在分布差异。形式化地，设 $\mathcal{D}_{\text{base}} = \{X_i, Y_i, y_i\}_{i=1}^{N}$ 为训练数据集，其中包含 N 张正常图像和异常图像，$X_i \in \mathcal{R}^{h\times w\times 3}$ 表示第 i 张图像，$Y_i \in \mathcal{R}^{h\times w}$ 和 $y_i = \{0, 1\}$ 分别表示对应的异常掩码和异常标签，其中 $y_i = 0$ 表示正常，$y_i = 1$ 表示异常。测试集 $\mathcal{T}$ 可以由多个不同领域组成，包含多种对象和异常类型。这里，我们将第 t 个新领域记为 $\mathcal{D}^{t}_{\text{novel}} = \{X_i, Y_i, y_i\}_{i=1}^{N_t}$。在少样本设定下，从目标域中每个类别随机抽取少量正常图像 $\mathcal{P}_c = \{X_i\}_{i=1}^{k}$，其中 c 是类别索引，k 通常是一个较小数值，例如 $k = \{1, 2, 4\}$。需要注意的是，$\mathcal{P}_c$ 仅在推理阶段可用，训练阶段不能以任何方式使用它。

总体概述：如图 2 所示，视觉适配器在固定的二分类文本提示嵌入下适配 patch token 和图像 token；文本适配器则学习二分类提示嵌入，以对齐固定的 patch token 和图像 token。提示-查询适配器以单提示元学习的方式工作，利用查询上下文特征与提示图像和查询图像之间对齐残差特征的联合分布。在零样本场景下，图像级异常分数和像素级异常图可由文本适配器和视觉适配器得到（第 3.2 节）。在少样本场景下，异常分数和异常图则通过融合零样本分支与提示-查询适配器的预测得到（第 3.3 节）。下面我们详细介绍这些模块。

3.1. 面向异常检测的 CLIP 再审视

对于查询图像 $X^q \in \mathcal{R}^{h\times w\times 3}$，我们将其输入视觉编码器 $\mathcal{F}(\cdot)$，得到局部 patch token $\{\boldsymbol{F}_i^q \in \mathcal{R}^d\}_{i=1}^{hw/p^2}$ 和全局图像 token $\boldsymbol{f}^q \in \mathcal{R}^d$，其中 p 是 patch 大小。WinCLIP [16] 引入了描述正常状态和异常状态的二分类提示。例如，“a photo of a normal object”和“a photo of a damaged object”。在实际应用中，可以为正常和异

常状态设计多种文本描述。将这些正常和异常描述输入文本编码器 $\mathcal{T}(\cdot)$，即可得到正常嵌入 $\boldsymbol{w}_n \in \mathcal{R}^d$ 和异常嵌入 $\boldsymbol{w}_a \in \mathcal{R}^d$。像素级异常图通过计算所有 patch token 与文本嵌入之间的余弦相似度获得，即

$$\hat{Y} = [\frac{\exp(\langle \boldsymbol{w}_a, \boldsymbol{F}_i^q \rangle)}{\exp(\langle \boldsymbol{w}_a, \boldsymbol{F}_i^q \rangle) + \exp(\langle \boldsymbol{w}_n, \boldsymbol{F}_i^q \rangle)}], \tag{1}$$

其中 $\langle \cdot \rangle$ 表示余弦相似度，$[\cdot]$ 表示将所有 patch 级预测分数按空间位置重新排列，并插值回原始输入分辨率。将式 1 中的 $\boldsymbol{F}_i^q$ 替换为 $\boldsymbol{f}^q$，即可得到 X^q 的图像级异常分数 $\hat{y}$，即

$$\hat{y} = \frac{\exp(\langle \boldsymbol{w}_a, \boldsymbol{f}^q \rangle)}{\exp(\langle \boldsymbol{w}_a, \boldsymbol{f}^q \rangle) + \exp(\langle \boldsymbol{w}_n, \boldsymbol{f}^q \rangle)}. \tag{2}$$

3.2. 带交替学习的 AdaptCLIP

为了让 CLIP 适应通用视觉异常检测，我们设计了视觉适配器和文本适配器，用于交替学习视觉表示和文本表示。具体来说，在固定二分类静态文本嵌入（$\boldsymbol{w}_a$ 和 $\boldsymbol{w}_n$）时，视觉适配器学习自适应视觉 token（$\boldsymbol{F}_i^{q\prime}$ 和 $\boldsymbol{f}^{q\prime}$）；在固定视觉 token（$\boldsymbol{F}_i^q$ 和 $\boldsymbol{f}^q$）时，文本适配器学习二分类文本提示嵌入（$\boldsymbol{w}_a'$ 和 $\boldsymbol{w}_n'$）。

视觉适配器。视觉适配器在固定文本嵌入（$\boldsymbol{w}_a$ 和 $\boldsymbol{w}_n$）的条件下，对视觉 token（$\boldsymbol{F}_i^q$ 和 $\boldsymbol{f}^q$）进行适配。它包含两个分支：全局分支和局部分支，分别作用于全局图像 token 和局部 patch token。从结构上看，这两个分支都由简单的残差多层感知机（MLP）实现，即

$$\boldsymbol{F}_i^{q\prime} = \boldsymbol{F}_i^q + \mathrm{MLP}(\boldsymbol{F}_i^q; \theta_v^l); \boldsymbol{f}^{q\prime} = \boldsymbol{f}^q + \mathrm{MLP}(\boldsymbol{f}^q; \theta_v^g), \tag{3}$$

其中 θ_v^l 和 θ_v^g 是可学习参数。将式 1 和式 2 中的 $\boldsymbol{F}_i^q$ 和 $\boldsymbol{f}^q$ 替换为 $\boldsymbol{F}_i^{q\prime}$ 和 $\boldsymbol{f}^{q\prime}$，即可得到像素级异常图 $\hat{Y}_v$ 和图像级异常分数 $\hat{y}_v$。

文本适配器。文本适配器旨在直接学习二分类提示 $\boldsymbol{\theta}_a, \boldsymbol{\theta}_n \in \mathcal{R}^{r \times d}$，无需手工提示模板，其中 $r > 0$ 是提示长度。我们将它们输入冻结的 CLIP 文本编码器 $\mathcal{T}(\cdot)$，得到相应的嵌入 $\boldsymbol{w}_a'$ 和 $\boldsymbol{w}_n'$，即

$$\boldsymbol{w}_a' = \mathcal{T}(\boldsymbol{\theta}_a), \boldsymbol{w}_n' = \mathcal{T}(\boldsymbol{\theta}_n). \tag{4}$$

随后，我们将式 1 和式 2 中静态的 $\boldsymbol{w}_a$ 和 $\boldsymbol{w}_n$ 替换为可学习提示嵌入 $\boldsymbol{w}_a'$ 和 $\boldsymbol{w}_n'$，从而得到局部和全局异常预测 $\hat{Y}_t$ 和 $\hat{y}_t$。

交替学习还是联合学习？一个自然问题是：我们是否可以联合学习视觉表示和文本表示。也就是说，在式 1 和式 2 中，同时将固定文本嵌入和视觉 token 替换为可学习提示嵌入（$\boldsymbol{w}_a'$ 和 $\boldsymbol{w}_n'$）以及自适应视觉 token（$\boldsymbol{F}_i^{q\prime}$ 和 $\boldsymbol{f}^{q\prime}$）。事实上，当拥有大规模图文数据集时，这种联合对齐机制是成功的。然而，我们在异常检测领域的实证结果表明，这种方式效果并不好。从消融实验可以看出，联合学习更容易过拟合。这并不令人意外，因为可用训练数据规模仍然相对较小，而且缺乏细粒度文本标注。联合学习容易过拟合，并导致在新数据集上的泛化能力变差。相比之下，交替学习可以帮助我们更充分地利用 CLIP 模型的先验知识，从而提升跨域泛化能力。

3.3. 带比较学习的 AdaptCLIP

与静态或可学习的文本提示相比，使用正常图像作为视觉提示更加直观。因此，我们希望学习查询图像 X^q 与其对应正常提示图像 X^p 之间的比较能力，使其能够泛化到未见对象。我们发现，使用多层特征会带来更好的结果。为简洁起见，以下仅以单层特征为例进行说明。

空间对齐：一种简单方式是直接计算二者残差特征的绝对值，即 $|\boldsymbol{F}_i^q - \boldsymbol{F}_i^p|$，其中 $\boldsymbol{F}_i^q$ 和 $\boldsymbol{F}_i^p$ 分别表示 X^q 和 X^p 的 patch token。但如果查询图像与提示图像在像素空间中未对齐（例如存在旋转或平移），这种做法可能失效。因此，为了实现有效比较，我们必须先对查询 token 和提示 token 进行对齐。对于任意查询 token $\boldsymbol{F}_i^q$，我们使用欧氏距离在所有正常 token $\{\boldsymbol{F}_j^p\}_{j=1}^{hw/p^2}$ 中搜索最近邻，即

$$\boldsymbol{F}_i^{p\prime} = \boldsymbol{F}_k^p, k = \arg\min_j \|\boldsymbol{F}_i^q - \boldsymbol{F}_j^p\|_2. \tag{5}$$

随后，我们将 $\boldsymbol{F}_i^{p\prime}$ 视为 $\boldsymbol{F}_i^q$ 的对齐提示 token。此时即可得到对齐后的残差特征，即 $|\boldsymbol{F}_i^q - \boldsymbol{F}_i^{p\prime}|$。

联合上下文特征与对齐残差特征：对齐后的残差特征能够较好地突出差异区域或异常区域，但它也可能丢失上下文信息或引入噪声。直观上，上下文信息对于识别异常至关重要。因此，我们通过逐元素求和，将原始查询 token 与对齐残差特征聚合起来：

$$\bar{\boldsymbol{F}}_i = \boldsymbol{F}_i^q + |\boldsymbol{F}_i^q - \boldsymbol{F}_i^{p\prime}|. \tag{6}$$

提示-查询适配器：我们的最终目标是同时实现像素级异常分割和图像级异常分类。因此，我们提出了一个轻量级分割头 $\mathcal{G}(\cdot; \theta_p^l)$，基于联合特征 $\bar{F}$ 学习异常分割，

即

$$\hat{Y}_p = \mathcal{G}(\bar{F}; \theta_p^l), \tag{7}$$

其中 θ_p^l 为其参数。具体而言，该分割头由一个 1×1 卷积层之后接若干反卷积块构成。每个反卷积块都将输入特征上采样 $2\times$，并由一个 3×3 卷积、一个 BatchNorm、一个 ReLU 以及一个 2×2 反卷积组成。

同时，我们还需要得到全局图像级预测。首先，我们对联合特征 $\bar{F}$ 沿空间维度进行平均池化和最大池化，并将两者的加权平均作为全局图像表示。随后，使用一个简单 MLP 将该全局特征映射为图像级预测分数，即

$$\hat{y}_p = \mathrm{MLP}\big((\mathrm{AvgPool}(\bar{F}) + \mathrm{MaxPool}(\bar{F}))/2; \theta_p^g\big), \tag{8}$$

其中 θ_p^g 为参数。

```
"""
image_encoder and textual_encoder: frozen CLIP model
visual_adapter: learned visual adapter
theta: learned two-class prompt embeddings
prompt_query_adapter: learned prompt-query adapter
Xq, Xp: query image and the normal image prompt
T:  fixed two-class textual prompts
inference_style: 'zero-shot' or 'few-shot' (default)
"""
# extract fixed visual and textual representations
Fq = image_encoder(Xq), W = textual_encoder(T)
# adapt visual tokens and textual embeddings, Eqs. 3 and 4
Fq_a = visual_adapter(Fq), W_a = textual_encoder(theta)

# AdaptCLIP via alternating learning for zero-shot AD
# compute anomaly map with softmax, Eq. 1
Yv = F.softmax(F.cosine_similarity(W, Fq_a))
Yt = F.softmax(F.cosine_similarity(W_a, Fq))
Y = (Yv + Yt)/2

# AdaptCLIP via comparative learning for few-shot AD
if inference_style == 'few-shot':
    Fp = image_encoder(Xp)
    # spatial alignment, Eq. 5
    Fp_a = Fp[torch.min((Fq - Fp)**2)[1], dim = -1)]
    # joint contextual and aligned residual feature, Eq. 6
    Fq_ = Fq + torch.abs(Fq - Fp_a)
    # perform anomaly segmentation, Eq. 7
    Yp = prompt_query_adapter(Fq_)
    Y = (Yv + Yt + Yp)/3
```

图 3. AdaptCLIP 推理过程的 PyTorch 伪代码。

3.4. 训练与推理

在训练阶段，我们使用交叉熵损失进行全局图像异常分类，并使用 Focal Loss 和 Dice Loss 进行局部 patch 异常分割，这与 AnomalyCLIP [53] 完全一致。在零样本推理时，我们对视觉适配器和文本适配器的预测取平均。在少样本推理时，我们将三个适配器的结果，即提示-查询适配器、视觉适配器和文本适配器的结果进行融合（即平均），作为 AdaptCLIP 的最终预测。图 3 给出了 AdaptCLIP 像素级推理的 PyTorch 伪代码，其中 $W = [\boldsymbol{w}_a{}^T; \boldsymbol{w}_n{}^T]$，$W_a = [\boldsymbol{w}_a'{}^T; \boldsymbol{w}_n'{}^T]$，$Fq$ 和 Fp 分别表示固定的 $\boldsymbol{F}_i^q$ 和 $\boldsymbol{F}_i^p$，而 Fq_a 和 Fp_a 分别表示自适应后的 $\boldsymbol{F}^{q'}$ 和对齐后的 $\boldsymbol{F}^{p'}$。这里我们省略了图像级推理，因为只需将局部 patch token 替换为全局图像 token 即可方便得到。

4. 实验

4.1. 实验设置

数据集：我们在多个工业和医疗领域的数据集上对 AdaptCLIP 进行了全面评估。在工业领域，我们使用 MVTec [3]、VisA [55]、BTAD [26]、MVTec3D [5]、DTD [1]、KSDD [38]、MPDD [17] 以及大规模的 Real-IAD [41]。在医疗领域，我们使用脑肿瘤检测数据集 Br35H [13] 与 COVID-19 [30]，以及胃肠道息肉数据集 Kvasir [18] 和 Endo [39]。这些数据集的详细介绍见附录。

评估指标：按照已有工作，我们在主文中使用 AUROC 评估图像级异常分类，使用 AUPR 评估像素级异常分割。这里我们特别强调，对于异常分割任务，AUPR 更合适，因为正常像素与异常像素之间的类别不平衡极其严重 [55]。在附录中，我们还提供了基于全部指标（包括 AUROC、AUPR 和 $F1_{\max}$）的详细对比。

训练与测试协议：遵循 AnomalyCLIP [53]，我们使用 MVTec 的测试数据训练 AdaptCLIP，并在其他数据集上评估零样本/少样本性能。对于 MVTec 的评估，则使用 VisA 的测试数据训练 AdaptCLIP。为保证公平比较，所有模型均采用相同的训练和评估协议。

对比方法：我们将 AdaptCLIP 与多种当前最先进的零样本/少样本异常检测方法进行比较，包括零样本的 WinCLIP [16]、AnomalyCLIP [53]、AdaCLIP [6]，以及少样本的 WinCLIP+ [16]、InCtrl [54] 和 AnomalyCLIP+。其中，AnomalyCLIP+ 是我们在 AnomalyCLIP [53] 基础上加入类似 WinCLIP+ 的 patch 级特征关联机制所构建的强基线。关于 AdaptCLIP 与这些对比方法的更多实现细节见附录。

4.2. 与零样本/少样本方法的比较

表 1 以及原文中的像素级结果表分别展示了 AdaptCLIP 在图像级异常分类和像素级异常分割任务上，与其他零样本/少样本方法在 8 个真实工业数据集和 4 个医疗异常检测数据集上的对比结果。需要

表 1. **工业和医疗领域上，图像级异常分类的 AUROC 对比结果**。最佳和次优结果分别用 红色 和 蓝色 标出。上标 † 表示该结果为我们在与 AnomalyCLIP 和 AdaptCLIP 相同训练测试协议下的复现结果。需要注意的是，这里展示的是每个数据集上所有类别的平均结果；每个类别的完整结果见附录。以下表格同理。

样本数	方法	工业									医疗		
		MVTec	VisA	BTAD	MVTec3D	DTD	KSDD	MPDD	Real-IAD	平均	Br35H	Covid	平均
0	WinCLIP [16]	90.4	75.5	68.2	69.4	95.1	92.9	61.5	67.0	77.5	80.5	66.4	73.5
	AdaCLIP† [6]	90.7	81.7	89.9	76.2	92.7	96.6	64.0	73.3	83.1	96.7	69.4	83.0
	AnomalyCLIP [53]	91.6	82.0	88.3	73.9	93.9	97.8	77.5	69.5	84.3	94.2	77.7	86.0
	AdaptCLIP-Zero	93.5	84.8	91.0	78.6	96.0	98.1	73.6	74.2	86.2	94.8	86.5	90.7

说明的是，由于 Br35H 和 Covid 缺少像素级标注，我们仅使用图像级指标评估这两个数据集；而 Kvasir 和 Endo 不包含正常图像，因此我们只报告其像素级指标结果。下面对这些结果进行分析。

工业领域上的泛化能力：总体来看，在 1-shot、2-shot 和 4-shot 三种少样本设定下，AdaptCLIP 在几乎所有工业数据集上都显著优于所有对比方法。随着提示图像数量增加，所有方法的性能整体上都会提高。具体来说，InCtrl [54] 由于在基础训练数据集上进行了额外微调，因此优于 WinCLIP [16]。AnomalyCLIP [53] 则进一步取得了更好的泛化性能，这验证了学习与对象无关提示的重要性。AdaptCLIP 的表现更为突出，相比 AnomalyCLIP [53] 有较大幅度提升（像素级 AUPR 提升约 10% 以上，图像级 AUROC 提升约 2% 以上），尤其在 VisA 和 Real-IAD 这类具有挑战性的大规模数据集上更明显。这揭示了基于联合上下文特征与对齐残差特征的比较学习，对于通用异常检测非常有效。在零样本设定下，AdaptCLIP-Zero 在异常分类上显著优于当前最先进的 AdaCLIP [6]，尽管其在工业异常分割上略弱一些。但 AdaptCLIP 结构更简单、可学习参数更少（0.6M，而 AdaCLIP 为 10.7M；详见原文效率对比表），并且从工业领域迁移到医疗领域时具有更好的泛化能力。此外，在仅有一张正常图像提示时，我们的 one-shot AdaptCLIP 也可以轻松超过零样本 AdaCLIP [6]。

医疗领域上的泛化能力：当使用在工业数据集（即 MVTec）上训练的同一模型时，AdaptCLIP 在医疗异常检测任务上，无论是零样本还是少样本设定，都表现出很强的能力。令人惊讶的是，它在图像级异常分类（AUROC 提升 6.3%）和像素级异常分割（AUPR 提升 8.6%）上都显著优于当前最先进的 AdaCLIP。值得注意的是，即使将正常图像提示替换为异常图像，我们的方法仍然有效。这对于一些不包含正常图像的特殊数据集（如 Kvasir 和 Endo）具有实际意义。这里的成功主要来自我们提出的空间对齐机制，以及“异常像素通常较为稀疏”这一强先验假设。

效率比较：我们通过参数量和前向推理时间来衡量模型复杂度和效率。与当前最先进方法相比，AdaptCLIP 在保持较强异常检测性能的同时，具有有竞争力的推理速度。从零样本扩展到单样本时，AnomalyCLIP+ 和我们的 AdaptCLIP 几乎不会增加额外推理时间，这与早期的 WinCLIP 不同。

定性结果：图 4 展示了在工业和医疗测试图像上的部分可视化结果。总体来看，少样本正常图像提示能够帮助 AdaptCLIP 更准确地分割异常，并比零样本方式产生更少的误检。

4.3. 与多样本方法的比较

在原文的多样本/全样本对比实验中，我们将少样本 AdaptCLIP 与多样本和全样本的统一异常检测模型进行了比较。结果表明，AdaptCLIP 优于较早的多样本方法 RegAD [15]，并与最新的 PromptAD [23] 相当。需要指出的是，PromptAD [23] 在目标域上需要利用少量正常图像重新训练，而我们的方法在目标域上仍然保持 training-free。此外，我们的方法也优于一些全样本方法，如 SimpleNet [25] 和 UniAD [48]，并与最新的 OneNIP [11] 具有竞争力。总的来说，尽管与当前最先进的全样本方法相比仍存在一些差距，但我们的方法在面向开放世界的通用异常检测场景中已经展现出很强的性能。

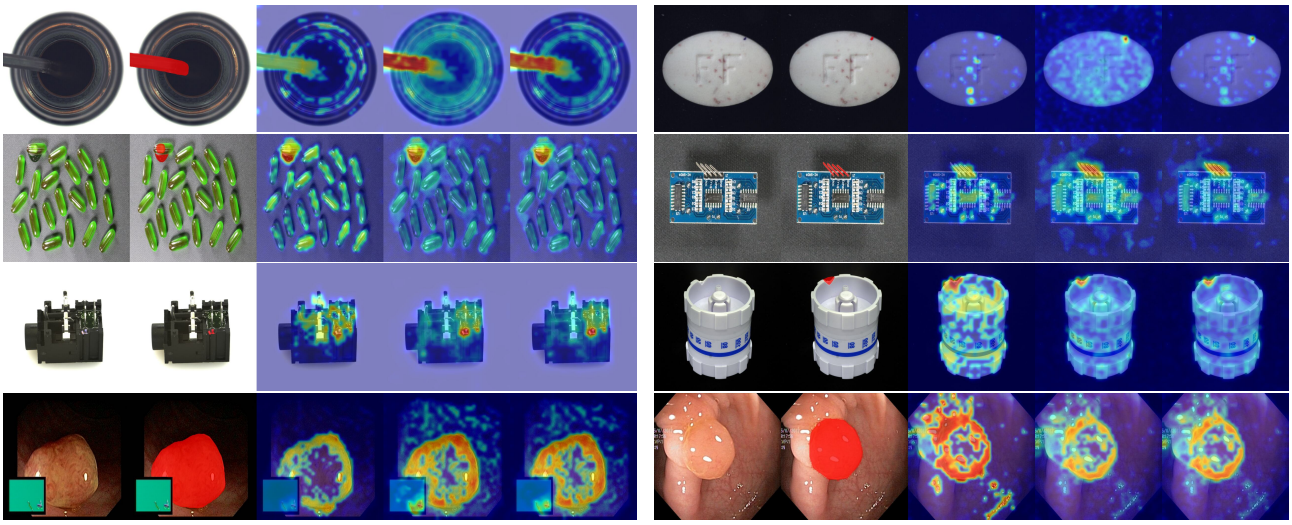

图 4. 我们的方法 AdaptCLIP 在 MVTec、VisA、Real-IAD、Kvasir 和 Endo 上，不同提示数量下的定性对比。更多定性结果见附录。建议彩色放大查看。

4.4. 消融实验

为了验证 AdaptCLIP 中三个适配器，即 TA（文本适配器）、VA（视觉适配器）和 PQA（提示-查询适配器），以及两个核心洞察，即交替学习和基于联合上下文特征与对齐残差特征的比较学习的有效性，我们在 MVTec 和 VisA 上进行了实验，详细结果见原文消融实验部分。

简单而有效的基线。第一个基线是朴素 CLIP（第 0 行），它仅使用二分类文本提示，就能简单而有效地完成零样本异常检测；但在像素级异常分割上仍然较弱。单独的文本适配器和视觉适配器则是另外两个基线。具体而言，文本适配器可以看作 AnomalyCLIP [53] 的极简版本，去除了文本提示模板和文本提示调优。这个简单的文本适配器在异常分类上优于原始 AnomalyCLIP 和朴素 CLIP，尽管在异常分割上略弱（第 0 行对比第 1 行）。视觉适配器则学习自适应的局部 patch token 和全局图像 token，以在 patch 级和图像级对齐 CLIP 的文本表示。这显著提升了像素级异常分割性能（第 0 行对比第 2 行）。

5. 结论

本文提出了一项通用异常检测任务，关注异常检测模型在跨领域（如工业和医疗）以及开放场景（如零样本或少样本设定）中的泛化能力。通用异常检测模型一旦训练完成，便无需在目标数据集上进行任何微调。与单独的零样本或少样本异常检测模型相比，通用异常检测模型更加灵活，既支持通过固定或可学习文本提示以及少量正常图像提示进行零样本/少样本推理，又能够同时提供图像级和像素级异常预测。我们提出了一个通用异常检测框架 AdaptCLIP，它通过交替学习自适应视觉表示与文本提示嵌入，并基于查询图像上下文信息与查询图像和提示图像之间对齐残差特征的联合表示进行比较学习。基于 8 个标准工业数据集和 4 个医疗数据集的大量实验表明，AdaptCLIP 在多种设置下都显著优于当前有竞争力的方法。

局限性： AdaptCLIP 在仅给定零样本/少样本正常图像提示时能够取得较好的异常检测性能。然而，如果将异常图像错误地作为正常图像提示提供给模型，可能会使模型混淆正常实例与异常实例，从而导致性能下降。幸运的是，在实际应用中，正常图像通常相对容易获取。此外，使用异常图像作为视觉提示也可能有效，因为即使在异常图像中，大多数像素通常仍然是正常的。

References

[1] Toshimichi Aota, Lloyd Teh Tzer Tong, and Takayuki Okatani. Zero-shot versus many-shot: Unsupervised texture anomaly detection. In *WACV*, 2023. 5

[2] Yoshua Bengio, Li Yao, Guillaume Alain, and Pascal Vincent. Generalized denoising auto-encoders as gen-

erative models. In *NeurIPS*, 2013. 2

[3] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec-AD: A comprehensive real-world dataset for unsupervised anomaly detection. In *CVPR*, 2019. 5

[4] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. Uninformed Students: Student-teacher anomaly detection with discriminative latent embeddings. In *CVPR*, 2020. 2

[5] Paul Bergmann., Xin Jin., David Sattlegger., and Carsten Steger. The mvtec 3d-ad dataset for unsupervised 3d anomaly detection and localization. In *VISAPP*, 2022. 5

[6] Yunkang Cao, Jiangning Zhang, Luca Frittoli, Yuqi Cheng, Weiming Shen, and Giacomo Boracchi. Adaclip: Adapting clip with hybrid learnable prompts for zero-shot anomaly detection. In *ECCV*, 2024. 1, 2, 5, 6

[7] Thomas Defard, Aleksandr Setkov, Angelique Loesch, and Romaric Audigier. PaDiM: a patch distribution modeling framework for anomaly detection and localization. In *ICPR*, 2021. 2

[8] Hanqiu Deng and Xingyu Li. Anomaly detection via reverse distillation from one-class embedding. In *CVPR*, 2022. 1, 2

[9] Choubo Ding, Guansong Pang, and Chunhua Shen. Catching both gray and black swans: Open-set supervised anomaly detection. In *CVPR*, 2022. 3

[10] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. FastRecon: Few-shot industrial anomaly detection via fast feature reconstruction. In *ICCV*, 2023. 3

[11] Bin-Bin Gao. Learning to detect multi-class anomalies with just one normal image prompt. In *ECCV*, 2024. 1, 2, 6

[12] Dong Gong, Lingqiao Liu, Vuong Le, Budhaditya Saha, Moussa Reda Mansour, Svetha Venkatesh, and Anton van den Hengel. Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection. In *ICCV*, 2019. 2

[13] Ahmed Hamada. Br35h: Brain tumor detection 2020, 2020. 5

[14] Jinlei Hou, Yingying Zhang, Qiaoyong Zhong, Di Xie, Shiliang Pu, and Hong Zhou. Divide-and-Assemble: Learning block-wise memory for unsupervised anomaly detection. In *ICCV*, 2021. 2

[15] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. In *ECCV*, 2022. 3, 6

[16] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *CVPR*, 2023. 1, 2, 3, 5, 6

[17] Stepan Jezek, Martin Jonak, Radim Burget, Pavel Dvorak, and Milos Skotak. Deep learning-based defect detection of metal parts: evaluating current methods in complex conditions. In *ICUMT*, 2021. 5

[18] Debesh Jha, Pia H Smedsrud, Michael A Riegler, Pål Halvorsen, Thomas de Lange, Dag Johansen, and Håvard D Johansen. Kvasir-seg: A segmented polyp dataset. In *International Conference on Multimedia Modeling*, pages 451–462, 2020. 5

[19] Jiarui Lei, Xiaobo Hu, Yue Wang, and Dong Liu. PyramidFlow: High-resolution defect contrastive localization using pyramid normalizing flow. In *CVPR*, 2023. 2

[20] Aodong Li, Chen Qiu, Marius Kloft, Padhraic Smyth, Maja Rudolph, and Stephan Mandt. Zero-shot anomaly detection via batch normalization. In *NeurIPS*, 2023. 2

[21] Chun-Liang Li, Kihyuk Sohn, Jinsung Yoon, and Tomas Pfister. CutPaste: Self-supervised learning for anomaly detection and localization. In *CVPR*, 2021. 2

[22] Xurui Li, Ziming Huang, Feng Xue, and Yu Zhou. MuSc: Zero-shot industrial anomaly classification and segmentation with mutual scoring of the unlabeled images. In *ICLR*, 2024. 2

[23] Xiaofan Li, Zhizhong Zhang, Xin Tan, Chengwei Chen, Yanyun Qu, Yuan Xie, and Lizhuang Ma. PromptAD: Learning prompts with only normal samples for few-shot anomaly detection. In *CVPR*, 2024. 1, 2, 3, 6

[24] Wenrui Liu, Hong Chang, Bingpeng Ma, Shiguang Shan, and Xilin Chen. Diversity-measurable anomaly detection. In *CVPR*, 2023. 2

[25] Zhikang Liu, Yiming Zhou, Yuansheng Xu, and Zilei Wang. SimpleNet: A simple network for image anomaly detection and localization. In *CVPR*, 2023. 1, 2, 6

[26] Pankaj Mishra, Riccardo Verk, Daniele Fornasier, Claudio Piciarelli, and Gian Luca Foresti. VT-ADL: A vision transformer network for image anomaly detection and localization. In *ISIE*, 2021. 5

[27] Pramuditha Perera, Ramesh Nallapati, and Bing Xiang. OCGAN: One-class novelty detection using GANs with constrained latent representations. In *CVPR*, 2019. 2

[28] Zhen Qu, Xian Tao, Mukesh Prasad, Fei Shen, Zhengtao Zhang, Xinyi Gong, and Guiguang Ding. Vcp-clip: A visual context prompting model for zero-shot anomaly segmentation. In *ECCV*, 2024. 2

[29] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *ICML*, 2021. 1, 2

[30] Tawsifur Rahman, Amith Khandakar, Yazan Qiblawey, Anas Tahir, Serkan Kiranyaz, Saad Bin Abul Kashem, Mohammad Tariqul Islam, Somaya Al Maadeed, Susu M Zughaier, Muhammad Salman Khan, et al. Exploring the effect of image enhancement techniques on covid-19 detection using chest x-ray images. *Computers in biology and medicine*, 2021. 5

[31] Rajesh PN Rao and Dana H Ballard. Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects. *Nature Neuroscience*, 2(1), 1999. 2

[32] Oliver Rippel, Patrick Mertens, and Dorit Merhof. Modeling the distribution of normal data in pretrained deep features for anomaly detection. In *ICPR*, 2021. 2

[33] Nicolae-Cătălin Ristea, Neelu Madan, Radu Tudor Ionescu, Kamal Nasrollahi, Fahad Shahbaz Khan, Thomas B Moeslund, and Mubarak Shah. Self-supervised predictive convolutional attentive block for anomaly detection. In *CVPR*, 2022. 2

[34] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *CVPR*, 2022. 1, 2

[35] Marco Rudolph, Tom Wehrbein, Bodo Rosenhahn, and Bastian Wandt. Fully convolutional cross-scale-flows for image-based defect detection. In *WACV*, 2022. 2

[36] Mohammadreza Salehi, Niousha Sadjadi, Soroosh Baselizadeh, Mohammad H Rohban, and Hamid R Rabiee. Multiresolution knowledge distillation for anomaly detection. In *CVPR*, 2021. 2

[37] Shelly Sheynin, Sagie Benaim, and Lior Wolf. A hierarchical transformation-discriminating generative model for few shot anomaly detection. In *ICCV*, 2021. 3

[38] Domen Tabernik, Samo Šela, Jure Skvarč, and Danijel Skočaj. Segmentation-based deep-learning approach for surface-defect detection. *Journal of Intelligent Manufacturing*, 31(3):759–776, 2020. 5

[39] David Vázquez, Jorge Bernal, F Javier Sánchez, Gloria Fernández-Esparrach, Antonio M López, Adriana Romero, Michal Drozdzal, Aaron Courville, et al. A benchmark for endoluminal scene segmentation of colonoscopy images. *Journal of healthcare engineering*, 2017, 2017. 5

[40] Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. In *ICML*, 2008. 2

[41] Chengjie Wang, Wenbing Zhu, Bin-Bin Gao, Zhenye Gan, Jiangning Zhang, Zhihao Gu, Shuguang Qian, Mingang Chen, and Lizhuang Ma. Real-iad: A real-world multi-view dataset for benchmarking versatile industrial anomaly detection. In *CVPR*, 2024. 5

[42] Guodong Wang, Shumin Han, Errui Ding, and Di Huang. Student-teacher feature pyramid matching for anomaly detection. *BMVC*, 2021. 2

[43] Shenzhi Wang, Liwei Wu, Lei Cui, and Yujun Shen. Glancing at the patch: Anomaly localization with global and local feature comparison. In *CVPR*, 2021. 2

[44] Guoyang Xie, Jingbao Wang, Jiaqi Liu, Feng Zheng, and Yaochu Jin. Pushing the limits of fewshot anomaly detection in industry vision: Graphcore. In *ICLR*, 2023. 3

[45] Xudong Yan, Huaidong Zhang, Xuemiao Xu, Xiaowei Hu, and Pheng-Ann Heng. Learning semantic context from normal samples for unsupervised anomaly detection. In *AAAI*, 2021. 2

[46] Xincheng Yao, Ruoqi Li, Zefeng Qian, Yan Luo, and Chongyang Zhang. Focus the Discrepancy: Intra-and inter-correlation learning for image anomaly detection. In *ICCV*, 2023. 2

[47] Xincheng Yao, Ruoqi Li, Jing Zhang, Jun Sun, and Chongyang Zhang. Explicit boundary guided semi-push-pull contrastive learning for supervised anomaly detection. In *CVPR*, 2023. 3

[48] Zhiyuan You, Lei Cui, Yujun Shen, Kai Yang, Xin Lu, Yu Zheng, and Xinyi Le. A unified model for multi-class anomaly detection. In *NeurIPS*, 2022. 1, 2, 6

[49] Muhammad Zaigham Zaheer, Jin-ha Lee, Marcella Astrid, and Seung-Ik Lee. Old is Gold: Redefining the adversarially learned one-class classifier training paradigm. In *CVPR*, 2020. 2

[50] Vitjan Zavrtanik, Matej Kristan, and Danijel Skočaj. DRAEM: A discriminatively trained reconstruction embedding for surface anomaly detection. In *ICCV*, 2021. 2

[51] Vitjan Zavrtanik, Matej Kristan, and Danijel Skočaj. Reconstruction by inpainting for visual anomaly detection. *PR*, 112, 2021. 2

[52] Ying Zhao. OmniAL: A unified cnn framework for unsupervised anomaly localization. In *CVPR*, 2023. 2

[53] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *ICLR*, 2024. 1, 2, 5, 6, 7

[54] Jiawen Zhu and Guansong Pang. Toward generalist anomaly detection via in-context residual learning with few-shot sample prompts. In *CVPR*, 2024. 1, 2, 3, 5, 6

[55] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. In *ECCV*, 2022. 5